ANALYSE DES DONNÉES DE VOLS 2015

CONDITIONS MÉTÉOROLOGIQUES ET RETARDS AU DÉPART

PROBLÉMATIQUE

Dans quelle mesure les conditions météorologiques influencent-elles les retards au départ des vols aux États-Unis en 2015 ?

KHAOULA SAIDI
[ÉTABLISSEMENT] — [FORMATION]
ANNÉE UNIVERSITAIRE 2026 | 2027

Introduction générale

Dans un contexte où le transport aérien joue un rôle essentiel dans la mobilité des personnes et le développement économique, la ponctualité des vols représente un enjeu majeur pour les compagnies aériennes et les passagers. Cependant, les retards de départ peuvent être causés par plusieurs facteurs, notamment les contraintes opérationnelles, la congestion des aéroports et les conditions météorologiques. Comprendre ces facteurs est donc important pour améliorer la gestion des vols et limiter les perturbations.

Ce projet s'inscrit dans une démarche d'analyse exploratoire des données (*Exploratory Data Analysis*), visant à étudier les vols effectués aux États-Unis en 2015 et à examiner plus particulièrement la relation entre les conditions météorologiques et les retards au départ. Pour cela, plusieurs sources de données sont exploitées, notamment les informations relatives aux vols, aux aéroports et aux observations météorologiques. À l'aide de Python et de bibliothèques spécialisées telles que Pandas, Matplotlib et Seaborn, les données sont préparées, nettoyées et analysées au moyen de statistiques descriptives, de visualisations et de méthodes statistiques.

La problématique centrale de ce projet est la suivante : **dans quelle mesure les conditions météorologiques influencent-elles les retards au départ des vols, en tenant compte des caractéristiques des aéroports, des compagnies aériennes et des périodes de départ ?**

L'objectif est d'identifier les principales tendances des retards, d'examiner les différences selon les conditions météorologiques et d'évaluer leur influence à l'aide de méthodes statistiques adaptées. Une attention particulière est également accordée aux annulations de vols, qui constituent une autre conséquence possible des conditions météorologiques défavorables.



Enfin, ce travail vise à transformer les données brutes en informations compréhensibles et utiles pour mieux appréhender les facteurs associés aux retards aériens. Les résultats permettront de distinguer l'influence des conditions météorologiques des autres facteurs étudiés, tout en tenant compte des limites des données disponibles.

Méthodologie

La démarche suivie repose sur un processus d'analyse de données en quatre étapes, allant de la définition de la question à la communication des résultats. Chaque étape a été mise en œuvre en Python à partir des données de vols de 2015 et des observations météorologiques associées.

ÉTAPE 1

DÉFINIR LA QUESTION

- Identifier la problématique et l'objectif
- Définir les indicateurs clés : retard au départ, annulation
- Formuler les hypothèses : l'effet de la météo sur les retards

ÉTAPE 2

COLLECTER ET NETTOYER LES DONNÉES

- Rassembler les fichiers vols, aéroports, compagnies et météo
- Traiter les valeurs manquantes et les doublons
- Harmoniser les formats et les fuseaux horaires
- Fusionner vols et observations météo

ÉTAPE 3

ANALYSER LES DONNÉES

- Analyse exploratoire : univariée, bivariée et multivariée
- Appliquer des tests statistiques et une régression avec contrôles
- Visualiser les résultats avec Matplotlib et Seaborn
- Interpréter dans le contexte : aéroports, compagnies, périodes

ÉTAPE 4

COMMUNIQUER LES RÉSULTATS

- Synthétiser les principaux enseignements
- Présenter les graphiques de manière claire
- Mettre en évidence l'impact sur les annulations
- Discuter les limites et les perspectives

> *Cette démarche permet de passer des données brutes à des conclusions fiables, en isolant l'effet des conditions météorologiques de celui des autres facteurs.*

II. Analyse exploratoire (EDA)

Objectif. Avant de chercher des liens entre les variables, on regarde chaque variable seule de la table `cleaned_flights` (vols réalisés). On répond à des questions simples : quand les avions partent-ils ? Les retards sont-ils fréquents ou rares ? Les vols sont-ils répartis régulièrement dans l'année ?

Étapes du code : 1) tracer un histogramme avec `hist()` pour les variables numériques ; 2) utiliser `describe()` pour obtenir moyenne, médiane et extrêmes ; 3) utiliser `catplot(kind='count')` pour compter les vols par mois et par jour.

5 714 008
vols réalisés analysés

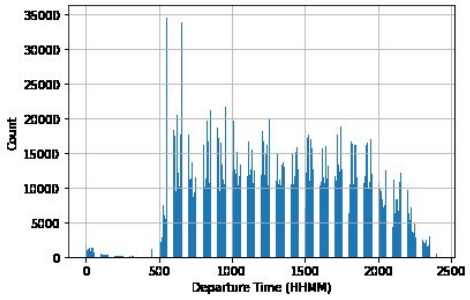
929
aéroports d'origine (et de destination)

−2 min
retard médian au départ (moyenne : +9,3 min)

HORAIRES ET RETARDS

1 Heures de départ

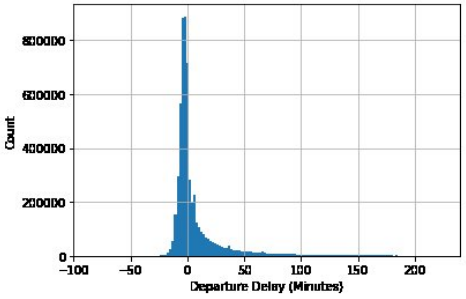
```
df['DEPARTURE_TIME'].hist(bins=1000)
```



Lecture : la plupart des vols partent entre 5 h et 23 h. Très peu de vols entre minuit et 5 h. Des « trous » apparaissent chaque heure : les départs se concentrent sur la première moitié de l'heure.

2 Retard au départ (zoom < 240 min)

```
df['DEPARTURE_DELAY'].hist(bins=1000)
plt.xlim((-100,240))
```



Lecture : la distribution est très étalée vers la droite : quelques très gros retards (jusqu'à 1 988 min). La majorité des vols part en avance ou avec moins de 20 minutes d'écart.

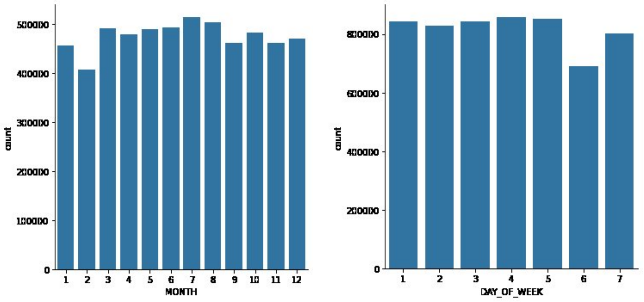
3 Statistiques du retard au départ

```
df['DEPARTURE_DELAY'].describe()
```

Indicateur	Valeur (min)
Moyenne	9,29
Écart-type	36,89
Minimum	−82
25 % / 50 % / 75 %	−5 / −2 / 7
Maximum	1 988

Lecture : la moitié des vols décolle 2 minutes avant l'heure prévue. La moyenne (9,3 min) est tirée vers le haut par quelques retards extrêmes.

4 Vols par mois et par jour




```
sns.catplot(x='MONTH', kind='count', ...)
sns.catplot(x='DAY_OF_WEEK', kind='count', ...)
```

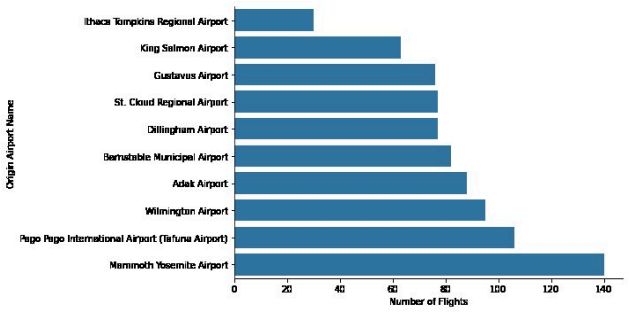
Lecture : le nombre de vols est presque constant tout au long de l'année (février un peu plus bas car plus court) et de la semaine (légèrement moins le samedi).

II. Analyse exploratoire (EDA)

AÉROPORTS ET TRAJETS

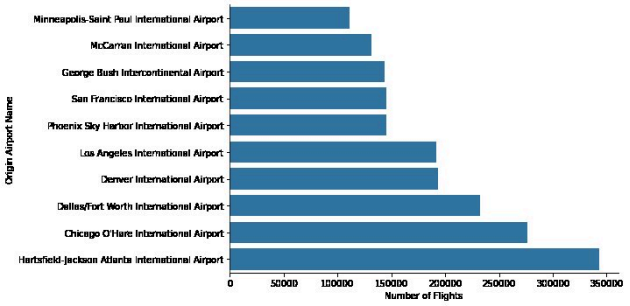
5 10 aéroports d'origine les plus actifs

```
origin_air_flights = df.groupby('ORIGIN_AIRPORT')
['FLIGHT_NUMBER'].count()
.sort_values()  # puis merge avec airports_df
```



Lecture : Atlanta (≈ 340 000 vols), Chicago O'Hare (≈ 275 000) et Dallas/Fort Worth (≈ 230 000) dominent largement. Les mêmes aéroports sont aussi les premières destinations.

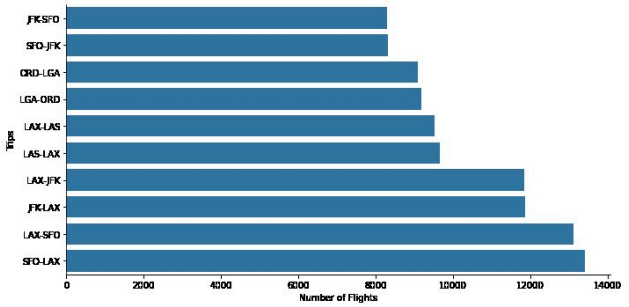
6 10 aéroports les moins actifs



Lecture : à l'inverse, de petits aéroports régionaux (Ithaca, King Salmon, Gustavus…) ne comptent que quelques dizaines de vols dans l'année.

7 10 trajets les plus fréquents

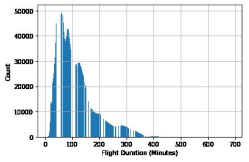
```
df['Trips'] = df['ORIGIN_AIRPORT'] + '-' +
df['DESTINATION_AIRPORT']
```



Lecture : SFO-LAX et LAX-SFO (≈ 13 000 vols) arrivent en tête. Chaque trajet a presque autant de vols dans les deux sens : les vols fonctionnent en aller-retour.

8 Durée en vol

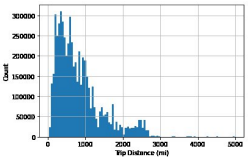
```
df['AIR_TIME'].hist(bins=1000)
```



Lecture : asymétrique à droite : la majorité des vols sont courts. Des « trous » réguliers apparaissent.

9 Distance parcourue

```
df['DISTANCE'].hist(bins=100)
```



Lecture : même forme : surtout des courtes distances, peu de vols très longs.

À retenir (analyse univariée)

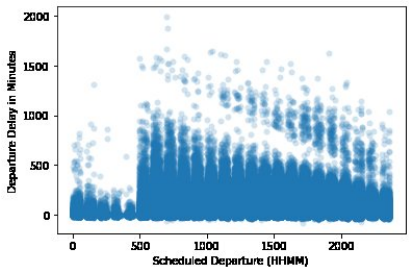
- Les vols sont répartis régulièrement dans l'année et la semaine, avec peu de vols la nuit.
- Le retard au départ est très asymétrique : beaucoup de vols à l'heure ou en avance, quelques retards très longs.
- L'activité est concentrée sur quelques grands aéroports (Atlanta, Chicago, Dallas).
- Les vols sont majoritairement courts, et fonctionnent en aller-retour.

II. Analyse exploratoire (EDA)

Objectif. On croise **deux variables** avec des nuages de points (`sns.scatterplot`) pour voir si elles évoluent ensemble. Un nuage qui monte ou descend indique un lien ; un nuage éparpillé indique l'absence de lien.

1 Heure prévue vs retard au départ

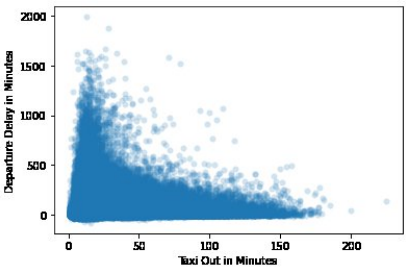
```
sns.scatterplot(x='SCHEDULED_DEPARTURE',
  y='DEPARTURE_DELAY', data=df, alpha=0.2)
```



Lecture : plus le départ est prévu tard dans la journée, plus le retard a tendance à s'accumuler (corrélation ≈ +0,11).

2 Taxi-out vs retard au départ

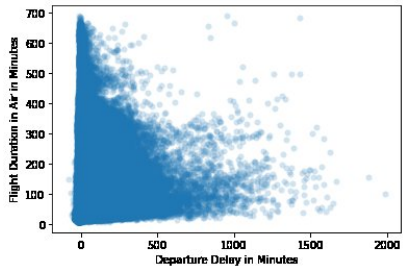
```
sns.scatterplot(x='TAXI_OUT',
  y='DEPARTURE_DELAY', data=df, alpha=0.2)
```



Lecture : relation en courbe : les très gros retards correspondent à des temps de roulage plus courts.

3 Retard au départ vs durée en vol

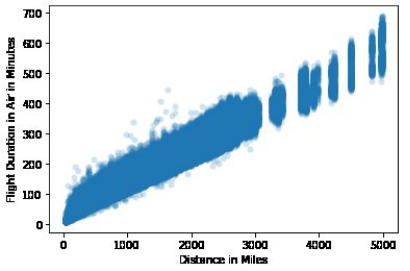
```
sns.scatterplot(x='DEPARTURE_DELAY',
  y='AIR_TIME', data=df, alpha=0.2)
```



Lecture : plus le vol est retardé, plus la durée en vol diminue : les pilotes semblent accélérer pour rattraper le retard.

4 Distance vs durée en vol

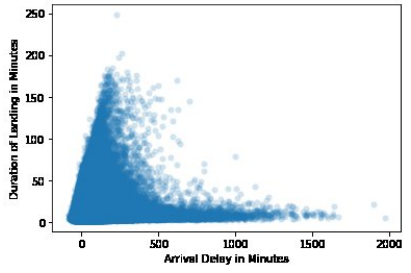
```
sns.scatterplot(x='DISTANCE',
  y='AIR_TIME', data=df, alpha=0.2)
```



Lecture : lien linéaire évident : plus la distance est grande, plus le vol est long. Les « trous » vus plus haut viennent de groupes de trajets de même longueur.

5 Retard à l'arrivée vs taxi-in

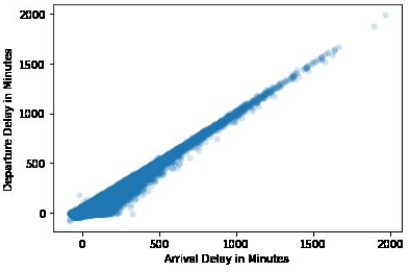
```
sns.scatterplot(y='TAXI_IN',
  x='ARRIVAL_DELAY', data=df, alpha=0.2)
```



Lecture : quand le vol est en retard, l'atterrissage et le roulage sont plus rapides.

6 Retard au départ vs retard à l'arrivée

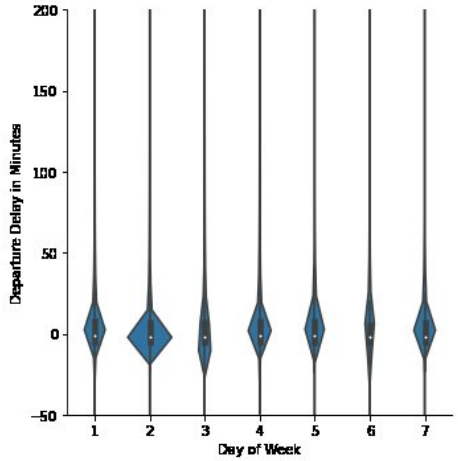
```
sns.scatterplot(y='DEPARTURE_DELAY',
  x='ARRIVAL_DELAY', data=df, alpha=0.2)
```



Lecture : un vol retardé au décollage arrive presque toujours en retard : la relation est très forte.

7 Retard au départ selon le jour de la semaine

```
sns.catplot(x='DAY_OF_WEEK', y='DEPARTURE_DELAY',
  data=df, kind='violin')
plt.ylim((-50,200))
```



Lecture : la forme des retards change d'un jour à l'autre : le mardi, les retards sont très concentrés autour de zéro, les autres jours sont plus dispersés et les longs retards plus fréquents vers le week-end.

8 Principales corrélations

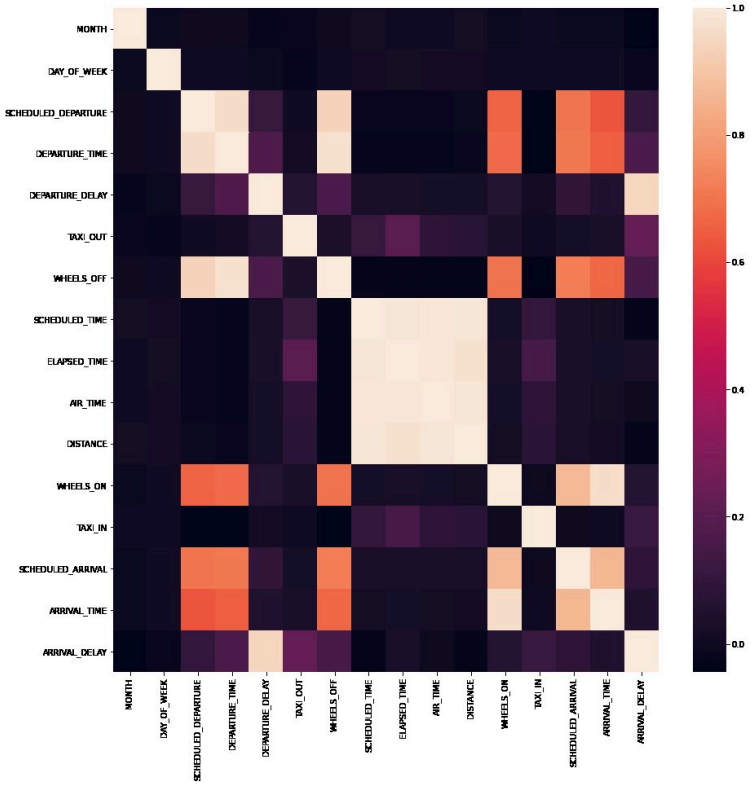
```
cor = df[numeric_columns].corr()
```

Variables	Corrélation
Départ prévu / départ réel	+0,96
Départ prévu / décollage (wheels off)	+0,94
Départ prévu / retard au départ	+0,11
Mois / retard au départ	−0,02

Lecture : les variables horaires sont évidemment très liées entre elles. Le retard dépend peu du mois pris seul.

9 Carte de chaleur des corrélations

```
sns.heatmap(cor, ax=ax)
```



Lecture : les cases foncées ou claires marquent les variables fortement liées (horaires, durées, retards). Elle résume les liens trouvés dans les nuages de points.

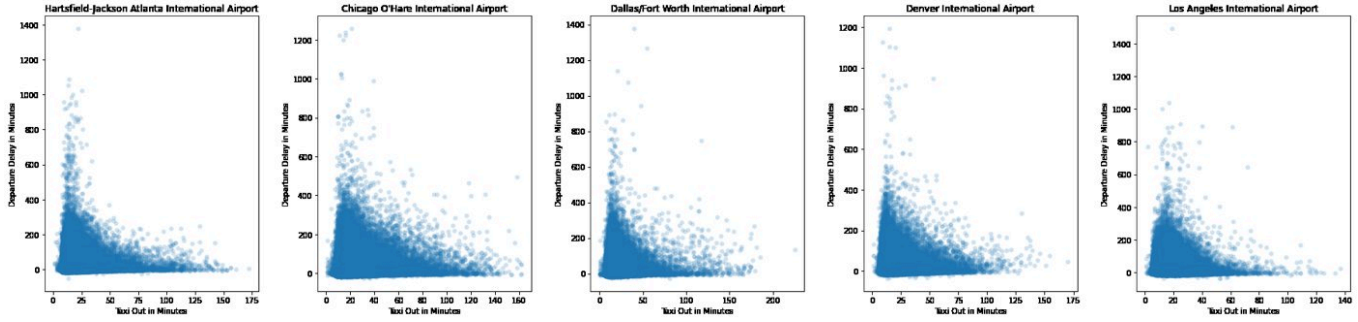
II. Analyse exploratoire (EDA)

MULTIVARIÉE

Objectif. On ajoute une **troisième variable** (l'aéroport ou le trajet) pour voir si les relations précédentes changent selon l'endroit. On compare les 5 aéroports les plus actifs côte à côte.

1 Roulage au départ et retard, par aéroport d'origine

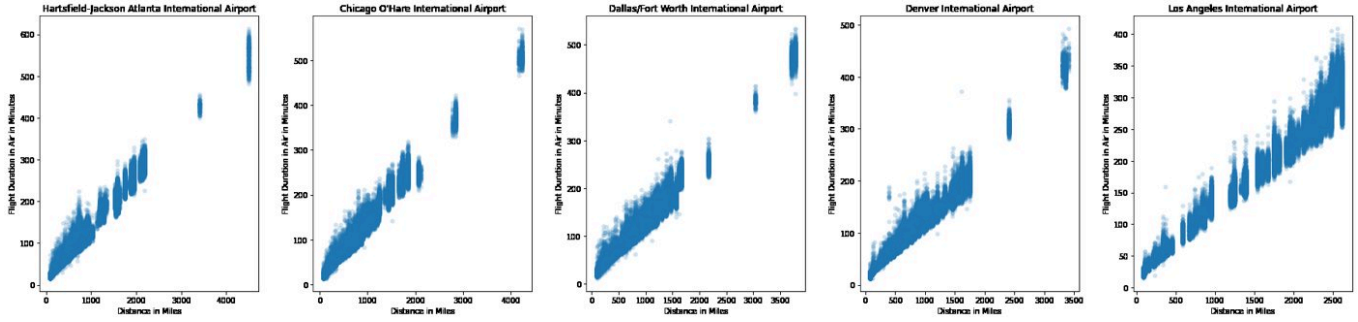
```
for i in range(1,6):
    sns.scatterplot(x='TAXI_OUT', y='DEPARTURE_DELAY',
       data=df[df['ORIGIN_AIRPORT']==origin_air_flights.iloc[-i,0]], alpha=0.2)
```



Lecture : la forme du nuage dépend de l'aéroport : les retards et les temps de roulage sont plus dispersés à Chicago O'Hare que dans les autres aéroports.

2 Distance et durée en vol, par aéroport d'origine

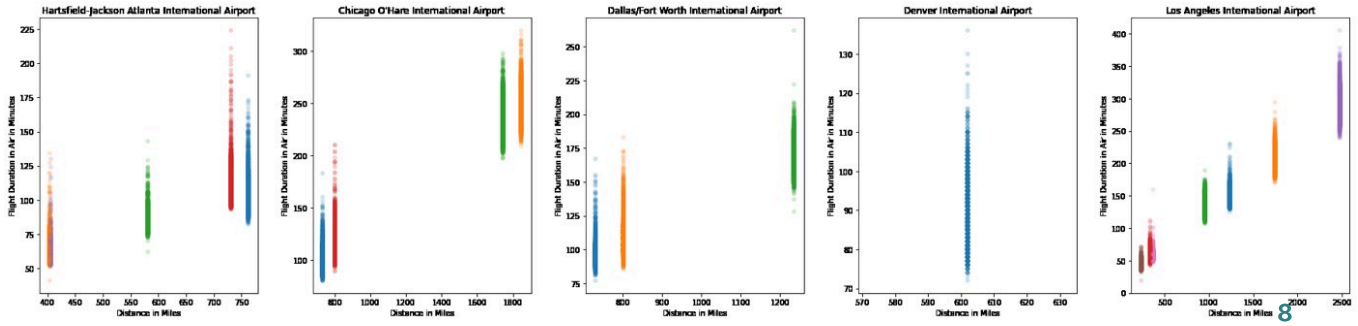
```
sns.scatterplot(x='DISTANCE', y='AIR_TIME', data=df[df['ORIGIN_AIRPORT']==...])
```



Lecture : à Los Angeles notamment, les points forment des groupes séparés : chaque groupe correspond à un trajet précis.

3 Distance et durée en vol, colorées par trajet

```
df['Trips'] = df['ORIGIN_AIRPORT'] + '-' + df['DESTINATION_AIRPORT']
sns.scatterplot(x='DISTANCE', y='AIR_TIME', hue='Trips', ...)
```



Lecture : avec une couleur par trajet, les « trous » de la durée en vol s'expliquent : ils viennent des groupes de trajets de longueurs différentes.

III. Météo et retards au départ

Question. La météo à l'aéroport de départ influence-t-elle les retards au départ, et de combien ? On utilise la table `cleaned_flights` (vols réalisés) et le fichier `usa_weather_2015.csv` : des observations **horaires** pour **27 villes américaines** en 2015 (température, humidité, pression, vent, description du temps), en heure UTC.

Limites du fichier météo : pas de mesure de visibilité ni de précipitations (pluie, neige, brouillard sont déduits du texte `weather_description`) ; seulement 27 villes, donc seuls les aéroports proches (≤ 40 km) sont utilisés ; la météo est mesurée au centre-ville, pas sur la piste.

1. Charger fichier météo › **2. Contrôler** valeurs manquantes, doublons › **3. Nettoyer** interpolation › **4. Créer** types de météo › **5. Relier** aéroport ↔ ville › **6. Fusionner** vol + météo › **7. Vérifier** fuseaux horaires

III.1 Chargement et contrôle qualité

```
weather_df = pd.read_csv(WEATHER_PATH,
                         parse_dates=['datetime'])
weather_df.isnull().sum()
weather_df.duplicated(['city','datetime']).sum()
```

Tableau des valeurs manquantes (sortie du notebook)

Ce qui est vérifié : dimensions, types, valeurs manquantes, doublons (ville, heure), nombre de villes, période couverte, cohérence des deux colonnes de température (K et °C).
Constat du notebook : 8 760 enregistrements horaires par ville, aucun doublon, peu de valeurs manquantes (vent, humidité) et horodatage en UTC (le maximum de température tombe l'après-midi heure locale).

III.2 Nettoyage des valeurs manquantes

```
weather[fill_cols] = weather.groupby('weather_city')
[fill_cols]
  .transform(lambda s: s.interpolate(limit=6,

limit_direction='both'))
# puis médiane de la ville s'il reste des trous
```

Explication simple : une heure manquante est estimée à partir des heures voisines de la même ville (interpolation, au maximum 6 heures de suite). S'il reste un trou, on prend la valeur médiane de la ville.

III.2 Types de météo créés

```
d = weather['weather_description'].str.lower()
weather['is_snow'] = d.str.contains('snow')
weather['is_fog']  = d.str.contains('fog')
weather['is_thunderstorm'] =
d.str.contains('thunderstorm|squall')
# ... pluie, forte pluie, brume, etc.
```

Explication simple : on transforme le texte de la météo en indicateurs « oui / non » (pluie, neige, brouillard, orage…). Ce sont des catégories, pas des mesures.

III.2 Une catégorie par heure

1. Orage
2. Neige / pluie verglaçante
3. Forte pluie
4. Pluie
5. Brouillard
6. Brume / brume sèche
7. Nuageux
8. Dégagé

Quand plusieurs phénomènes sont présents, le plus sévère l'emporte.

III.2 Conditions « extrêmes »

Elles sont définies **par rapport au climat de chaque ville** : 1 % des heures les plus venteuses, 1 % les plus froides et 1 % les plus chaudes de la ville (35 °C est normal à Phoenix et exceptionnel à Seattle), plus la météo sévère (orages, pluie verglaçante, forte pluie, forte neige, rafales).

III. Météo et retards au départ

III.3 Relier chaque aéroport à une ville météo

```
def haversine_km(lat1, lon1, lat2, lon2): ...
MAX_KM = 40
# station météo la plus proche, limite 40 km
```

Explication simple : pour chaque aéroport, on cherche la ville météo la plus proche. Au-delà de 40 km on exclut l'aéroport plutôt que de lui donner la météo d'un lieu éloigné. JFK, LaGuardia et Newark partagent la météo de New York ; Oakland celle de San Francisco. Chaque ville reçoit aussi son fuseau horaire (Phoenix n'a pas d'heure d'été).

III.4 Fusionner vols et météo

```
k['weather_utc'] = utc.dt.round('h')
flights_w = cleaned_flights.merge(weather,
    on=['weather_city','weather_utc'])
```

Explication simple : l'heure de départ **prévue** (heure locale) est convertie en UTC puis arrondie à l'heure, et on joint la météo de la ville d'origine à cette heure. On utilise l'heure prévue et non réelle, car l'heure réelle contient déjà le retard (jointure circulaire).

III.4 Diagnostic de la fusion

```
diag = pd.DataFrame({'N_flights': [...]}, index=[...])
display(diag)
```

1. origine codée par un nombre (pas un code IATA)
2. aéroport à plus de 40 km d'une ville météo
3. heure locale ambiguë (changement d'heure)
4. pas d'observation météo à cette heure

Tableau des diagnostics (sortie du notebook)

Le tableau indique la part des vols qui ont pu être reliés à la météo. Sont exclus :

III.4 Vérification des fuseaux horaires

```
t_profile = flights_w.groupby(
  ['weather_city','local_hour'])
['temperature_C'].mean().unstack()
assert 13 <= t_profile.idxmax(axis=1).median() <= 18
```

Courbes de température par heure locale (sortie du notebook)

Principe : si la conversion heure locale → UTC est correcte, la température moyenne de chaque ville doit culminer l'après-midi (≈ 15-16 h heure locale). Le code s'arrête avec une erreur sinon.

À retenir (préparation)

- Le fichier météo est complet et en UTC ; les rares trous sont comblés par interpolation.
- Le texte de la météo est converti en catégories ordonnées par sévérité.
- Chaque vol reçoit la météo de sa ville d'origine à l'heure prévue de départ, avec contrôle des fuseaux horaires.
- Seuls les vols partant d'aéroports proches des 27 villes forment l'échantillon d'analyse.

III. Météo et retards au départ

III.5 Retard moyen par type de météo

```
delay_summary(flights_w, 'weather_group')
# N_flights, mean_delay, median_delay,
# p90_delay, pct_delayed_15
```

Tableau et barres du retard par type de météo

Ce que montre le tableau : pour chaque type de météo, le nombre de vols, le retard moyen, médian, le 90e percentile et le % de vols retardés de 15 min ou plus. **Attention :** ces moyennes brutes mélangent aéroports, saisons et heures (la neige tombe au nord, en hiver) ; la régression (III.8) isole l'effet réel.

III.5 Température, vent, humidité, pression

```
pd.cut(flights_w['temperature_C'], bins, labels)
g['DEPARTURE_DELAY'].mean()  # + IC 95 %
```

Barres par classe (4 variables météo)

Ce que montre le graphique : pour chaque variable découpée en classes, le retard moyen (avec intervalle de confiance à 95 %) et le % de vols retardés. Température et humidité dépendent du lieu et de la saison : le résultat brut ne suffit pas.

III.5 Corrélations météo / retards

```
pearson  = df[weather_vars+delay_vars].corr()
spearman = df[...].corr(method='spearman')
sns.heatmap(mat, annot=True, cmap='RdBu_r')
```

Cartes de chaleur Pearson et Spearman

Lecture : une corrélation proche de 0 = pas de lien. On s'attend à des valeurs **faibles** : la plupart des retards ont des causes opérationnelles (avion en retard, équipage, congestion) sans rapport avec la météo. Spearman (par rangs) est plus fiable car les retards sont très asymétriques.

III.5 Boîtes à moustaches

```
sns.boxplot(data=flights_w, x='DEPARTURE_DELAY',
  y='weather_group', showfliers=False)
```

Boxplots par type de météo, température, vent, humidité

Lecture : la médiane et l'écart interquartile bougent peu selon la météo : la météo agit surtout sur la **queue** de la distribution (les longs retards), mieux vue par la moyenne et le % de retards ≥ 15 min.

III.5 Neige, brouillard et visibilité

```
flights_w['visibility_proxy'] = np.select([fog, mist_haze, precip],
  ['Fog','Mist / haze / smoke','Precipitation'], default='No restriction')
```

Tableau et boxplots de la visibilité (sortie du notebook)

Explication simple : le fichier ne contient pas de visibilité, donc brouillard, brume et fortes précipitations servent d'**indicateurs** de visibilité réduite. Un second tableau compare l'intensité de la neige (neige légère, neige, forte neige).

III. Météo et retards au départ

III.6 Conditions extrêmes

```
flag_effect(flights_w, 'severe_weather')
# Mann-Whitney, chi², risk ratio
```

Tableau des effets (sortie du notebook)

Explication simple : pour chaque événement (orage, neige, brouillard, vent fort, grand froid, grande chaleur…) on compare le retard avec les autres vols : écart en minutes, % de retards ≥ 15 min, **rapport de risque** (supérieur à 1 = plus de retards) et taille d'effet. Avec des millions de vols les p-values sont toutes minuscules : c'est la **taille** de l'effet qui compte.

III.7 Test de Kruskal-Wallis

```
H, p = stats.kruskal(*groups)
eps2 = H / (len(flights_w) - 1)
```

H, p et ε^2 (sortie du notebook)

Explication simple : ce test vérifie si le retard diffère selon le type de météo. Il sera « significatif » vu la taille de l'échantillon ; **ε^2** indique son importance réelle : proche de 0 = la météo seule explique peu pourquoi un vol donné est en retard.

III.8 Régression avec contrôles

```
# Modèle 1 : retard en minutes (OLS)
# Modèle 2 : P(retard ≥ 15 min)
X = pd.concat([W, C], axis=1)   # météo + contrôles
```

Coefficients avec intervalles à 95 %

Explication simple : on mesure l'effet de la météo à **aéroport, compagnie, mois, jour et heure constants** (référence : ciel dégagé). Chaque coefficient = minutes (ou points de pourcentage) de retard en plus par rapport au ciel dégagé. L'**R^2 incrémental** mesure la part de variabilité expliquée par la météo ; il est petit car la météo sévère est rare.

III.9 Aéroports les plus sensibles

```
adv = df[df['adverse']].groupby('ORIGIN_AIRPORT')
['DEPARTURE_DELAY'].mean()
extra_delay = mean_adverse - mean_benign
```

Top 15 des aéroports (sortie du notebook)

Explication simple : pour chaque aéroport, retard moyen par temps défavorable (orage, neige, forte pluie, brouillard) moins retard moyen par temps clair ou nuageux. Les aéroports de moins de 200 vols par mauvais temps sont exclus. Le type de météo diffère selon l'aéroport (neige à Boston, orages à Houston).

III.10 Annulations

```
canc['cancelled_weather'] =
(canc['CANCELLATION_REASON']=='B')
canc.groupby('weather_group')['CANCELLED'].mean()
```

% de vols annulés par type de météo

Explication simple : la météo provoque aussi des annulations (raison B). Un vol annulé n'a pas de retard : l'analyse des retards **sous-estime** donc l'impact réel de la neige et des orages.

Comment lire les conclusions

1. **La météo influence-t-elle les retards ?** Oui si les coefficients des catégories sévères sont positifs, intervalles loin de 0, et si le rapport de risque dépasse 1.
2. **De combien ?** Voir les minutes, les points de pourcentage et le R^2 incrémental.
3. **Non capturé :** annulations, retards propagés des vols précédents, météo à destination ou en route, conditions sur la piste, vols hors des 27 villes.

Conclusion et perspectives

Conclusion

Ce projet a étudié les vols réalisés aux États-Unis en 2015 (plus de 5,7 millions de vols) pour répondre à la question : **dans quelle mesure la météo influence-t-elle les retards au départ ?** Les données ont été nettoyées, explorées (analyses univariée, bivariée et multivariée), puis reliées aux observations météo de 27 villes pour mesurer l'effet de chaque type de temps, avec contrôle de l'aéroport, de la compagnie, du mois, du jour et de l'heure.

Résultats principaux

01 **Retards asymétriques.** La moitié des vols décolle 2 minutes en avance ou à l'heure (médiane −2 min), mais la moyenne est de +9,3 min à cause de rares retards très longs (jusqu'à 1 988 min).

02 **Activité concentrée.** Atlanta, Chicago O'Hare et Dallas/Fort Worth concentrent le plus de départs ; SFO-LAX est le trajet le plus fréquent, et les trajets fonctionnent en aller-retour.

03 **Les retards se propagent.** Un retard au départ se retrouve presque toujours à l'arrivée ; il augmente aussi avec l'heure prévue de départ, et le profil des retards varie selon le jour de la semaine et l'aéroport.

04 **Démarche météo.** Les observations météo sont jointes à chaque vol par ville et par heure UTC. L'effet est mesuré par tests non paramétriques et régression avec contrôles ; les effets chiffrés (en minutes et en rapport de risque) sont à renseigner à partir des sorties du notebook.

Limites du travail

01 Seulement 27 villes météo : les vols au départ d'aéroports situés à plus de 40 km, ou codés par un nombre, sont exclus.

02 Pas de visibilité ni de précipitations mesurées : pluie, neige et brouillard sont déduits du texte de la météo (catégories, pas mesures). La météo est relevée au centre-ville, pas sur la piste.

03 Les vols annulés ou déroutés sont absents de l'analyse des retards, qui sous-estime donc l'impact de la météo sévère ; les valeurs manquantes ont été imputées (mode, médiane).

04 Les résultats décrivent des associations et non des causes ; les retards hérités des vols précédents ne sont pas visibles dans la météo du départ.

Améliorations, références et annexes

Améliorations possibles

01 Utiliser des données météo plus fines (METAR par aéroport avec visibilité, précipitations, plafond nuageux) et couvrir davantage d'aéroports.

02 Prendre en compte la météo à destination et la propagation des retards (avion précédent, rotation des équipages).

03 Compléter par des modèles prédictifs (régression logistique, forêts aléatoires) pour prévoir un retard ≥ 15 min, et étudier les annulations en détail.

Références bibliographiques

[1] U.S. Department of Transportation, Bureau of Transportation Statistics. *Airline On-Time Performance Data* (2015). Jeu de données diffusé sur Kaggle : « 2015 Flight Delays and Cancellations » (`flights.csv`, `airports.csv`, `airlines.csv`).

[2] Jeu de données météo horaire de 27 villes américaines, 2015 (`usa_weather_2015.csv`) — source exacte à préciser.

[3] McKinney, W. (2010). *Data Structures for Statistical Computing in Python*. Proceedings of the 9th Python in Science Conference (pandas).

[4] Hunter, J. D. (2007). *Matplotlib: A 2D Graphics Environment*. Computing in Science & Engineering, 9(3), 90-95.

[5] Waskom, M. L. (2021). *seaborn: statistical data visualization*. Journal of Open Source Software, 6(60), 3021.

[6] Virtanen, P. et al. (2020). *SciPy 1.0: fundamental algorithms for scientific computing in Python*. Nature Methods, 17, 261-272.

Annexes

Annexe A : variables principales

Variable	Signification
`DEPARTURE_DELAY`	Retard au départ en minutes (négatif = en avance)
`DELAYED_15`	1 si le retard au départ est de 15 min ou plus
`TAXI_OUT` / `TAXI_IN`	Temps de roulage au départ / à l'arrivée
`AIR_TIME`, `DISTANCE`	Durée en vol (min) et distance (miles)
`weather_group`	Catégorie de météo la plus sévère de l'heure
`CANCELLATION_REASON`	A compagnie, B météo, C trafic aérien, D sécurité

Annexe B : outils. Python, pandas, NumPy, Matplotlib, seaborn, SciPy ; code complet dans le notebook `2015-flights-data-analysis_weather.ipynb`.